

- מטריצת Covariance
- PDF/CDF
- Matlab
- הערכות לבוחן

משנים אקראיים גאוסיים

סכימה הרצאה קצרה: התפלגות גאוסית ב-2 ממדים של שני משנים X_1, X_2

→ צורה כישור

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right)$$

$\underline{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$: וקטור משנים
 $\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$: תוחלת
 $\begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$: Cov (מטריצת קווריאנס)

מקדם קורלציה

$$\rho = \frac{\text{Cov}[X_1, X_2]}{\sqrt{\text{Var}[X_1] \text{Var}[X_2]}}$$

$$X_1 \sim N(\mu_1, \sigma_1^2)$$

$$X_2 \sim N(\mu_2, \sigma_2^2)$$

שאלת תוחלת

Covariance

מטריצה: מטריצה שמימאלית

הערה:

$$C_X = \begin{bmatrix} \overset{1)}{\text{Cov}[X_1, X_1]} & \overset{2)}{\text{Cov}[X_1, X_2]} \\ \overset{3)}{\text{Cov}[X_2, X_1]} & \overset{4)}{\text{Cov}[X_2, X_2]} \end{bmatrix} = \begin{bmatrix} \text{Var}[X_1] & \text{Cov}[X_1, X_2] \\ \text{Cov}[X_1, X_2] & \text{Var}[X_2] \end{bmatrix}$$

סימון של מטריצה Cov.

תכונות:

- 1) $\text{Cov}[X, X] = \text{Var}[X]$
- 2) $\text{Cov}[X, Y] = \text{Cov}[Y, X]$

שאלת X_1 שאלת X_2 שאלת X_1, X_2

T-transpose

$$C_X = C_X^T \quad \text{Cov}[X_i, X_j] = \text{Cov}[X_j, X_i]$$

תכונת חשיבות: * סימטריה

* עבור X_1, X_2 חסרי קורלציה $\Leftrightarrow \text{Cov}[X_1, X_2] = 0$ → תנאי לחסרי קורלציה

$$C_X = \begin{bmatrix} \text{Var}[X_1] & 0 \\ 0 & \text{Var}[X_2] \end{bmatrix}$$

מטריצה אלכסונית

$$\text{Cov}[X_1, X_2] = \rho \sigma_1 \sigma_2$$

* בהתאמה σ_1, σ_2 שגורם

$$\rho = \frac{\text{Cov}[X_1, X_2]}{\sigma_1 \sigma_2} \quad \sigma_1 = \sqrt{\text{Var}[X_1]} \quad \sigma_2 = \sqrt{\text{Var}[X_2]}$$

מקדם קורלציה

במקרה של 2 צורה של מטריצה Cov היא

$$C_X = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

צורה:

תכונות: Cov

$$a_1 X_1 + a_2 X_2 \sim N$$

כיוון k : X_1, X_2 תפלגות גאוסית משותפת

כיוון k : X_1, X_2 הם גאוסים

תכונות:

משפטים. משתנים אקראיים X_1, X_2, \dots, X_N הם גאוסיים במשותף (בעלי התפלגות גאוסית N-ממדית משותפת) אם ורק אם הקומבינציה לינארית $\sum_{m=1}^N a_m X_m$ היא מתפלגת גאוסית עבור $\forall a_m \in \mathbb{R}$.

דוגמה 4.3: נתונים זוג משתנים אקראיים, $X \sim N(0, \sigma^2), Y = 3X$

$k=0$

(א) הראה שמשותפים X, Y הם גאוסיים במשותף.

$$X \sim N(0, \sigma^2)$$

$$Y = 3X$$

דוגמה 4.3: נתונים זוג משתנים אקראיים, $X \sim N(0, \sigma^2)$, $Y = 3X$.

$$X \sim N(0, \sigma^2)$$

$$Y = 3X$$

(א) הראה שמשותפים X, Y הם גאוסיים במשותף.

(ב) מהי מטריצת covariance? מהי התפלגות המשותפת שלהם?

פתרון: (א)

$$a_1 X + a_2 Y = a_1 X + 3a_2 X = (a_1 + 3a_2) X \sim N(0, (a_1 + 3a_2)^2 \sigma^2)$$

משמע: $Var[aX + b] = a^2 Var[X]$ (תוצאה)

למעשה קיבוצי גאוסיות

$$Var[X] = \sigma^2$$

$$Var[aX] = a^2 \sigma^2$$

בהתאם למשפט: אם $a_1 X_1 + a_2 X_2$ גאוסית אז X_1, X_2 גאוסיים

(ב)

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix} \right)$$

Covariance matrix

$$Var[X] = \sigma^2$$

$$Var[Y] = Var[3X] = 3^2 Var[X] = 9\sigma^2$$

$$E[XY] = E[3X \cdot X] = 3E[X^2] = 3\sigma^2$$

תוצאה:

$$Var[X] = E[X^2] - E^2[X]$$

$$E[X^2] = Var[X] + E^2[X] = \sigma^2$$

$$E[X] = 0 \quad E[Y] = E[3X] = 3E[X] = 0$$

$$\Rightarrow Cov[X, Y] = E[XY] - E[X]E[Y] = E[XY] = 3\sigma^2$$

סיכום:

$$C_X = \begin{bmatrix} Cov[X_1, X_1] & Cov[X_1, X_2] \\ Cov[X_2, X_1] & Cov[X_2, X_2] \end{bmatrix} = \sigma^2 \begin{bmatrix} 1 & 3 \\ 3 & 9 \end{bmatrix}$$

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, C_X \right)$$

מציאה: * \checkmark הדיאגנל של X, Y אין התפלגות גאוסית משותפת, אבל אין שם גורם להם בגורם התפלגות גאוסית * \checkmark תלויים, חסרי קורלציה

$$X \sim N(0, 1)$$

$$Y = WX \sim N(0, 1)$$

$$W = p(W = \pm 1) = \frac{1}{2}$$

$$p(W = 1) = \frac{1}{2}$$

$$p(W = -1) = \frac{1}{2}$$

$$E[W] = 1 \cdot \frac{1}{2} + (-1) \cdot \frac{1}{2} = 0$$

$$E[X^2 W] = E[X^2] = 1$$

$$Cov[X, Y] = E[XY] - E[X]E[Y] = E[X^2 W] - 0 = 0$$

$$|X| = |Y|$$

אין בעלי התפלגות גאוסית משותפת. מצב של $p(X + Y = 0) = \frac{1}{2}$ לא יכול לקראות עבור התפלגות רציפה (בוודאי גם גאוסית). "רצפה"

$$Y = WX$$

$$p(X + WX = 0) = p(X(W+1) = 0)$$

$$W+1 \Rightarrow p(W+1) = 0, \frac{1}{2}$$

תכונות של משתנים גאוסיים במשותף

חיזוי לינארי (הגדרה 4.9): עבור משתנים גאוסיים במשותף, החיזוי לינארי הוא חיזוי אופטימלי (אין חיזוי יותר טוב ממנו).

זוג משתנים גאוסיים במשותף PDF (הגדרה 4.10): ה-PDF המשותף של זוג משתנים גאוסיים

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right)$$

נתון ע"י

$$(4.21) \quad f_{X_1 X_2}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left(-\frac{1}{2(1-\rho^2)} \times \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} - \frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} \right] \right)$$

צורת ה-PDF (תכונה 4.7): ניתן לשים לב, שביטוי בתוך $\exp()$ הוא אליפסה מהצורה

$$(4.22) \quad \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} - \frac{2\rho(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} \right] = c^2$$

עבור מקרי קצה

□ $\rho = 0$ המשתנים הם חסרי קורלציה, והצורה היא צורת מעגל.




□ $\rho = \pm 1$ קשר לינארי, והצורה היא קו ישר.

$$\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} 2 \\ -2 \end{bmatrix} \quad C_x = \begin{bmatrix} 1 & \rho \\ \rho & 4 \end{bmatrix}$$

$$\sigma_1^2 = 1$$

$$\sigma_2^2 = 2^2$$

$$\rho = 0 \quad \frac{1}{2} \quad 0.95$$



* התפלגות שולית של X_1, X_2


$$X_1 \sim N(\mu_1, \sigma_1^2)$$

$$X_2 \sim N(\mu_2, \sigma_2^2)$$

בלתי תלויים! במקרים ק

* ככל ש- ρ אוכל / קטן יותר,

האליפטורה מתחילה סביב
והייתה צורה אחת.



$N(\mu_1, \sigma_1^2)$ (אנחנו מכוונים זה)

CDF

(נסכורת):







קשר בין PDF ל-CDF (תכונה 4.1):

$$F_{XY}(x, y) = p(X \leq x, Y \leq y)$$

$$F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(s, p) dp ds$$

CDF $F_{XY}(x, y)$

בהינתן $p(a < X \leq b, c < Y \leq d)$ חשב



$F_{XY}(b, c)$ (IV)

$$p(a < X \leq b, c < Y \leq d) = F_{XY}(b, d) - F_{XY}(a, d) - F_{XY}(b, c) + F_{XY}(a, c)$$

התפלגות באוסף 13-13

ניתן עיבוד מספר גלגל (Matlab זיך)

פרמטרים
 הנתונים

ρ

$F_X(a,b)$

→ ערך הנתון

```

mu1 = 0;
mu2 = 0;
sigma1 = 1;
sigma2 = 2;
rho = 0.5;
mu = [mu1; mu2];
Cv = [sigma1^2 rho*sigma1*sigma2; ...
      rho*sigma1*sigma2 sigma2^2];

a = 0;
b = 0;
% F(a,b)
mvncdf([a; b],mu, Cv) % mvn = multivariate normal
  
```