



המחלקה להנדסת חשמל ואלקטרוניקה

תאריך הבחינה: 23.02.2025

שעות הבחינה: 13:30-16:30

## מבוא לאותות אקראיים

מועד א'

ד"ר דימה בחובסקי, מר טל פאר

תשפ"ה סמסטר א'

חומר עזר - דף נוסחאות אישי (עמוד אחד), מחשבון

הוראות מיוחדות:

- השאלון כולל שאלות ללא בחירה, סך הכל של 120 נקודות.
- סעיפים הם בעלי ניקוד זהה, אלא אם צוין אחרת.
- יש לציין באופן מלא וברור את שלבי הפתרון. תשובה ללא הסבר לא תתקבלנה.
- במקום בו נדרש חישוב מספרי, יש קודם לרשום את הנוסחא, ורק אח"כ להציב!
- יש לציין יחידות למספרים, ובמידה וקיימות!
- כל השרטוטים יהיו גדולים, ברורים, עם סימון צירים!
- אין חובה להגיע לערך מספרי של הפונקציה  $Q(x)$ , במידה ומופיעה בתשובה.

השאלון כולל 13 דפים (כולל דף זה)

בהצלחה !



## 1 משתנה אקראי בדיד (30 נק')

נתונות זוג קוביות. מהי ההסתברות לתוצאה (6, 6) בנסיבות הבאות:

(א) רק אחרי לפחות 10 זריקות קוביה, או יותר?

(ב) לפחות פעם אחת (פעם אחת או יותר), מתוך 10 זריקות.

(ג) רק פעם אחת בלבד, מתוך 10 זריקות.

## 2 התפלגות דו-ממדית (40 נק')

נתונים זוג משתנים אקראיים בלתי תלויים,  $X \sim \text{Ber}(p_1)$ ,  $Y \sim \text{Ber}(p_2)$ , בעלי התפלגות משותפת,

$$p_{XY}[0, 0] = 0.08$$

$$p_{XY}[0, 1] = 0.32$$

$$p_{XY}[1, 0] = 0.12$$

$$p_{XY}[1, 1] = 0.48$$

(א) מהם ערכי  $p_1, p_2$ ?

עבור יתר הסעיפים, יש להשאיר  $p_1, p_2$  כפרמטרים.

(ב) נדרש חיזוי של  $X$  ע"י קבוע  $b_x$  עבורו שגיאה ריבועית היא מינימלית. מהי שגיאת החיזוי המתקבלת?

(ג) נתון הקשר,

$$(1) \quad Z = aX + cY$$


נדרש חיזוי של  $Z$  ע"י קבוע  $b_z$  עבורו מתקבלת שגיאה ריבועית מינימלית, ומהי שגיאת החיזוי?

(ד) האם קיימים קבועים  $a \neq 0, c \neq 0$ , כדי שהמשתנים  $Z, X$  יהיו חסרי קורלציה? אם כן, מהו התנאי המתקבל?

## 3 אותות גאוסיים ומערכות (40 נק')

נתונות 3 מערכות  $h_1[n], h_2[n], h_3[n]$  בעלי כניסה  $x[n]$  ומוצא  $y_1[n], y_2[n], y_3[n]$  כמתואר באיור.

האות הכניסה הוא רעש לבן גאوسي בעל  $R_x[k] = 4\delta[k]$ .




איור 1: שלוש מערכות בעלי אותה כניסה.

תגובות תדר של המערכות (מסננים אידיאליים עם השהייה) הן

$$H_1(f) = \begin{cases} e^{-j2f} & |f| \leq 0.15 \\ 0 & \text{אחרת} \end{cases}, \quad H_2(f) = \begin{cases} e^{-j2f} & 0.1 \leq |f| \leq 0.2 \\ 0 & \text{אחרת} \end{cases}, \quad H_3(f) = \begin{cases} e^{-j2f} & 0.2 \leq |f| \leq 0.3 \\ 0 & \text{אחרת} \end{cases} \quad (2)$$

שאלות:



איור 2: תגובות התדר של המערכות.

(א) מהי התפלגות של  $y_1[n]$ ? יש לפרט את סוג ההתפלגות וכל הפרמטרים המתבקשים.

(ב) (30 נק') מהי התפלגות המשותפת של הוקטור  $\begin{bmatrix} y_1[n] \\ y_2[n] \\ y_3[n] \end{bmatrix}$ ? יש לפרט את סוג ההתפלגות המשותפת וכל הפרמטרים.



## 4 חציון (10 נק')

בשנת 2023 נתוני השכר בישראל הם:

□ שכר **ממוצע** של 8,027 ש"ח

□ שכר **חציוני** של 6,543 ש"ח.

המשמעות היא **(יש לרשום את כל התשובות הנכונות בחוברת הבחינה):**

- (א) רוב האנשים מקבלים שכר יותר נמוך משכר מומצע.
- (ב) רוב האנשים מקבלים שכר יותר גבוה משכר מומצע.
- (ג) בקירוב, חצי האנשים מקבלים שכר מעל הממוצע, וחצי מתחת.
- (ד) רוב האנשים מקבלים שכר יותר נמוך משכר חציוני.
- (ה) רוב האנשים מקבלים שכר יותר גבוה משכר חציוני.
- (ו) בקירוב, חצי האנשים מקבלים שכר מעל ערך חציוני, וחצי מתחת.

# Random Processes – Formulas

## 1 Distributions

### 1.1 Continuous

	Notation	PDF	CDF	$E[X]$	$\text{Var}[X]$
Uniform	$U[a,b]$	$\begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{otherwise} \end{cases}$	$\begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & b < x \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normal	$N(\mu, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$	$\Phi(x)$	$\mu$	$\sigma^2$
Exponential	$Exp(\lambda)$	$\lambda \exp(-\lambda x), x \geq 0$	$1 - \exp(-\lambda x)$	$1/\lambda$	$1/\lambda^2$

#### 1.1.1 Q-function

$$\begin{array}{lcl} \text{Given } Y \sim N(\mu, \sigma^2) & & Q(x) = 1 - \Phi(x) \quad (3) \\ \frac{Y - \mu}{\sigma} \sim N(0, 1) & (1) & Q(-x) = 1 - Q(x) \quad (4) \\ p(Y > y) = Q\left(\frac{y - \mu}{\sigma}\right) & (2) & Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty \exp\left(-\frac{s^2}{2}\right) ds \quad (5) \end{array}$$

### 1.2 Discrete

	Notation	PDF	CDF	$E[X]$	$\text{Var}[X]$
Bernoulli	$\text{Ber}(p)$	$\begin{cases} 1-p & k=0 \\ p & k=1 \end{cases}$	$\begin{cases} 0 & x < 0 \\ 1-p & 0 \leq x < 1 \\ 1 & 1 \leq x \end{cases}$	$p$	$p(1-p)$
Binomial	$\text{Bin}(n, p)$	$\binom{n}{k} p^k (1-p)^{n-k}$		$np$	$np(1-p)$
Geometric	$\text{Geo}(p)$	$p(1-p)^{k-1}$	$1 - (1-p)^k$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

$\binom{n}{k} = \frac{n!}{(n-k)!k!}$

## 2 Random Variables

$$\begin{array}{lcl} \text{Definitions:} & & f_X(x) \geq 0 \quad (10) \\ F_X(x) = p(X \leq x) & (6) & \int_{-\infty}^{\infty} f_X(x) dx = 1 \quad (11) \\ f_X(x) = \frac{\partial F_X(x)}{\partial x} \geq 0 & (7) & p_X[x_k] = \Pr[X = x_k] \quad (12) \\ F_X(x) = \int_{-\infty}^x f_X(p) dp & (8) & 0 \leq p_X[x_i] \leq 1 \quad \forall i \quad (13) \\ p(a < X \leq b) = F_X(b) - F_X(a) & (9) & \sum_i p_X[x_i] = 1 \quad (14) \end{array}$$

$$F_X(x) = \Pr(X \leq x), \quad x \in \mathbb{R} \quad (15)$$

$$F_X(x) = \sum_{k: x_k \leq x} p_X[x_k] \quad (16)$$

Expectation:

$$E[X] = \begin{cases} \int_{-\infty}^{\infty} x f_X(x) dx \\ \sum_i x_i p_X[x_i] \end{cases} \quad (17a)$$

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx \\ \sum_i g(x_i) p_X[x_i] \end{cases} \quad (17b)$$

$$E[aX + b] = aE[X] + b \quad (17c)$$

Variance:

$$\begin{aligned} \text{Var}[X] &= E[(X - E[X])^2] \\ &= E[X^2] - E^2[X] \end{aligned} \quad (18a)$$

$$\text{Var}[aX + b] = a^2 \text{Var}[X] \quad (18b)$$

$$\text{Var}[b] = 0 \quad (18c)$$

Median: Value of  $m$ , such that  $\Pr(X \leq m) \geq \frac{1}{2}$  and  $\Pr(X \geq m) \geq \frac{1}{2}$

## 2.1 Numerical calculation

$$E[X] = \frac{1}{N} \sum_{i=1}^N x_i \quad (19)$$

$$\text{Var}[X] = \frac{1}{N} \sum_{i=1}^N (x_i - E[X])^2 \quad (20)$$

## 2.2 Histogram

$$p_X[x_i] \approx \frac{n_i}{N} \quad i = 1, \dots, k \quad (21)$$

$$f_X(x_i) \approx \frac{n_i}{N} \cdot \frac{1}{\Delta x} \quad i = 1, \dots, k \quad (22)$$

# 3 Two Random Variables

## 3.1 Joint Distributions

Definitions:

$$F_{XY}(x, y) = p(X \leq x, Y \leq y) \quad (23a)$$

$$f_{XY}(x, y) = \frac{\partial^2 F_{XY}(x, y)}{\partial x \partial y} \geq 0 \quad (23b)$$

$$F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(s, p) dp ds \quad (23c)$$

$$p[x_j, y_k] = p(X = x_j, Y = y_k) \quad (24a)$$

$$F_{XY}(x, y) = p(X \leq x_j, Y \leq y_k) \quad (24b)$$

Expectation:

$$E[g(X, Y)] = \begin{cases} \iint g(x, y) f_{XY}(x, y) dx dy \\ \sum_i \sum_k g(x_i, y_k) p_{XY}[x_i, y_k] \end{cases} \quad (25a)$$

$$E[aX + bY] = aE[X] + bE[Y] \quad (25b)$$

For **independent** random variables:

$$f_{XY}(x, y) = f_X(x) f_Y(y) \quad (26a)$$

$$p_{XY}[x_k, y_j] = p_X[x_k] p_Y[y_j] \quad (26b)$$

$$F_{XY}(x, y) = F_X(x) F_Y(y) \quad (26c)$$

$$(26d)$$

**Independent** random variables properties:

$$E[XY] = E[X]E[Y] \quad (27a)$$

$$E[g_1(X)g_2(Y)] = E[g_1(X)]E[g_2(Y)] \quad (27b)$$

$$\text{Var}[aX + bY] = a^2 \text{Var}[X] + b^2 \text{Var}[Y] \quad (27c)$$

Marginal distribution:

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y) dy \quad (28a)$$

$$p_X[x_k] = \sum_j p_{XY}[x_k, y_j] \quad (28b)$$

$$F_X(x) = F_{XY}(x, \infty) \quad (28c)$$

$$F_Y(y) = F_{XY}(\infty, y) \quad (28d)$$

## 3.2 Correlation, Covariance & Correlation Coefficient

- For two jointly-distributed random variables  $X$  and  $Y$ , covariance is given by

$$\begin{aligned} \text{Cov}[X, Y] &= E[(X - E[X])(Y - E[Y])] \\ &= E[XY] - E[X]E[Y] \end{aligned} \quad (29)$$

Main covariance properties are:

$$\text{Cov}[X, X] = \text{Var}[X] \quad (30a)$$

$$\text{Cov}[X, Y] = \text{Cov}[Y, X] \quad (30b)$$

$$\text{Cov}[X, a] = 0 \quad (30c)$$

$$\text{Cov}[aX, bY] = ab \text{Cov}[X, Y] \quad (30d)$$

$$\text{Cov}[X, Y] = \text{Cov}[X + a, Y + b] \quad (30e)$$

$$\begin{aligned} \text{Var}[aX \pm bY] &= a^2 \text{Var}[X] + b^2 \text{Var}[Y] \\ &\pm 2ab \text{Cov}[X, Y] \end{aligned} \quad (30f)$$

- Correlation coefficient (also termed as Pearson product-moment correlation coefficient) is given by

$$\rho_{XY} = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X] \text{Var}[Y]}} \quad (31)$$

such that  $|\rho_{XY}| \leq 1$ .

### 3.3 MMSE Linear Prediction

Mean square error (MSE) of predictor  $\hat{Y}$  is given by

$$mse = E[(Y - \hat{Y})^2] \quad (32)$$

Linear prediction of  $\hat{Y} = ax + b$  for  $X = x$  is

$$\hat{Y} = E[Y] + \frac{\text{Cov}[X, Y]}{\text{Var}[X]} (x - E[X]) \quad (33)$$

and

$$mse_{min} = E \left[ \left( Y - (aX + b) \right)^2 \right] = \text{Var}[Y] (1 - \rho_{XY}^2) \quad (34)$$

When  $X, Y$  are jointly Gaussian, this prediction is optimal among **all** possible predictors

### 3.4 Relations

- When  $X$  and  $Y$  are *orthogonal*,  $E[XY] = 0$ .

- When  $X$  and  $Y$  are *uncorrelated*,  $\text{Cov}[X, Y] = \rho_{XY} = 0$ .

- When  $X$  and  $Y$  are *independent*, they are also uncorrelated (see also Eqs. 26).

- When  $X$  and  $Y$  are *jointly* Gaussian and uncorrelated  $\Rightarrow X$  and  $Y$  are independent.

### 3.5 Bi-variate Normal Distribution

Joint Gaussian distribution of  $X_1$  and  $X_2$

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N \left( \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \mathbf{C}_X \right) \quad (35)$$

with covariance matrix

$$\mathbf{C}_X = \begin{bmatrix} \text{Cov}[X_1, X_1] & \text{Cov}[X_1, X_2] \\ \text{Cov}[X_2, X_1] & \text{Cov}[X_2, X_2] \end{bmatrix} \quad (36)$$

Important properties:

- Sum of independent Gaussian variables is a Gaussian variable.
- Random vector  $[X_1, \dots, X_n]$  is **jointly** Gaussian distributed, iff (if and only if) for all possible real vectors  $\mathbf{a} = (a_1, \dots, a_n)^T$  linear combination  $Y = a_1 X_1 + \dots + a_n X_n$  is Gaussian distributed.
- If jointly distributed Gaussian random variables are *uncorrelated*, they are also *independent*

## 4 Random Processes – General Properties

- PDF & CDF

$$F_{\mathbf{x}}(x; t) = p(\mathbf{x}(t) \leq x) \quad (37a)$$

$$f_{\mathbf{x}}(x; t) = \frac{\partial}{\partial x} F_{\mathbf{x}}(x; t) \quad (37b)$$

$$p_{\mathbf{x}}[x_k; n] = p(\mathbf{x}[n] = x_k) \quad (37c)$$

- Average:

$$E[\mathbf{x}(t)] = \int_{-\infty}^{\infty} x f_{\mathbf{x}}(x; t) dx \quad (38a)$$

$$E[\mathbf{x}[n]] = \sum_i x_i p_{\mathbf{x}}[x_k; n] \quad (38b)$$

- Variance:

$$\text{Var}[\mathbf{x}(t)] = E[\mathbf{x}^2(t)] - E^2[\mathbf{x}(t)] = \sigma_{\mathbf{x}}^2(t) \quad (39a)$$

$$\text{Var}[\mathbf{x}[n]] = E[\mathbf{x}^2[n]] - E^2[\mathbf{x}[n]] = \sigma_{\mathbf{x}}^2[n] \quad (39b)$$

- Auto-correlation

$$R_{\mathbf{x}}(t_1, t_2) = E[\mathbf{x}(t_1)\mathbf{x}(t_2)] \quad (40a)$$

$$R_{\mathbf{x}}(t, t + \tau) = E[\mathbf{x}(t)\mathbf{x}(t + \tau)] \quad (40b)$$

$$R_{\mathbf{x}}(t_1, t_2) = R_{\mathbf{x}}(t_2, t_1) \quad (40c)$$

$R_{\mathbf{x}}(t, t) = E[\mathbf{x}^2(t)]$	(40d)	• Correlation Coefficient	
$R_{\mathbf{x}}[n_1, n_2] = E[\mathbf{x}[n_1]\mathbf{x}[n_2]]$	(40e)		
$R_{\mathbf{x}}[n, n] = E[\mathbf{x}^2[n]]$	(40f)		
• Auto-covariance			
$C_{\mathbf{x}}(t_1, t_2) = E[\{\mathbf{x}(t_1) - E[\mathbf{x}(t_1)]\} \{\mathbf{x}(t_2) - E[\mathbf{x}(t_2)]\}]$	(41)	– When $\mathbf{x}(t_1)$ and $\mathbf{x}(t_2)$ are <i>orthogonal</i> ,	$\rho_{\mathbf{x}}(t_1, t_2) = \frac{C_{\mathbf{x}}(t_1, t_2)}{\sqrt{C_{\mathbf{x}}(t_1, t_1)C_{\mathbf{x}}(t_2, t_2)}} \quad (46a)$
$= R_{\mathbf{x}}(t_1, t_2) - E[\mathbf{x}(t_1)]E[\mathbf{x}(t_2)]$	(42)	$R_{\mathbf{x}}(t_1, t_2) = 0.$	$ \rho_{\mathbf{x}}(t_1, t_2)  \leq 1 \quad (46b)$
$C_{\mathbf{x}}[n_1, n_2] = E[\{\mathbf{x}[n_1] - E[\mathbf{x}[n_1]]\} \{\mathbf{x}[n_2] - E[\mathbf{x}[n_2]]\}]$	(43)	– When $\mathbf{x}(t_1)$ and $\mathbf{x}(t_2)$ are <i>uncorrelated</i> ,	
$= R_{\mathbf{x}}[n_1, n_2] - E[\mathbf{x}[n_1]]E[\mathbf{x}[n_2]]$	(44)	$C_{\mathbf{x}}(t_1, t_2) = \rho_{\mathbf{x}}(t_1, t_2) = 0.$	
		• Power	
$C_{\mathbf{x}}(t, t) = \text{Var}[\mathbf{x}(t)]$	(45a)		$P_{\mathbf{x}}(t) = E[\mathbf{x}^2(t)] \quad (47a)$
$C_{\mathbf{x}}[n, n] = \text{Var}[\mathbf{x}[n]]$	(45b)		$P_{\mathbf{x}}[n] = E[\mathbf{x}^2[n]] \quad (47b)$

## 5 Wide-Sense Stationary (WSS) Process

Definition:

$$E[\mathbf{x}(t)] = E[\mathbf{x}(0)] = \mu_{\mathbf{x}} = \text{const} \quad (48a)$$

$$R_{\mathbf{x}}(t_1, t_2) = R_{\mathbf{x}}(\tau = |t_2 - t_1|), \quad \forall t_1, t_2 \quad (48b)$$

$$E[\mathbf{x}[n]] = E[\mathbf{x}[0]] = \mu_{\mathbf{x}} = \text{const} \quad (48c)$$

$$R_{\mathbf{x}}[n_1, n_2] = R_{\mathbf{x}}(k = |n_2 - n_1|), \quad \forall n_1, n_2 \quad (48d)$$

• Auto-correlation

$$R_{\mathbf{x}}(\tau) = E[\mathbf{x}(t)\mathbf{x}(t + \tau)] \quad (49a)$$

$$R_{\mathbf{x}}[k] = E[\mathbf{x}[n]\mathbf{x}[n + k]] \quad (49b)$$

Properties:

$$R_{\mathbf{x}}(-\tau) = R_{\mathbf{x}}(\tau) \quad (50a)$$

$$R_{\mathbf{x}}(0) = E[|\mathbf{x}(0)|^2] = E[|\mathbf{x}(t)|^2] \quad (50b)$$

$$\text{Var}[\mathbf{x}(t)] = C_{\mathbf{x}}(0) = \sigma_{\mathbf{x}}^2 \quad (50c)$$

$$R_{\mathbf{x}}(0) \geq |R_{\mathbf{x}}(\tau)| \quad (50d)$$

• Auto-covariance

$$C_{\mathbf{x}}(\tau) = R_{\mathbf{x}}(\tau) - \mu_{\mathbf{x}}^2 \quad (51a)$$

$$C_{\mathbf{x}}[k] = R_{\mathbf{x}}[k] - \mu_{\mathbf{x}}^2 \quad (51b)$$

• Correlation Coefficient

$$\rho_{\mathbf{x}}(\tau) = \frac{C_{\mathbf{x}}(\tau)}{C_{\mathbf{x}}(0)} \quad (52a)$$

$$\rho_{\mathbf{x}}[k] = \frac{C_{\mathbf{x}}[k]}{C_{\mathbf{x}}[0]} \quad (52b)$$

### 5.1 Power Spectral Density (PSD)

$$S_{\mathbf{x}}(F) = \mathcal{F}\{R_{\mathbf{x}}(\tau)\} = \int_{-\infty}^{\infty} R_{\mathbf{x}}(\tau) \exp(-j2\pi F\tau) d\tau \quad -\infty \leq F \leq \infty \quad (53a)$$

$$R_{\mathbf{x}}(\tau) = \mathcal{F}^{-1}\{S_{\mathbf{x}}(F)\} = \int_{-\infty}^{\infty} S_{\mathbf{x}}(f) \exp(j2\pi F\tau) dF \quad (53b)$$

$$S_{\mathbf{x}}(f) = \text{DTFT}\{R_{\mathbf{x}}[k]\} = \sum_{k=-\infty}^{\infty} R_{\mathbf{x}}[k] e^{-j2\pi f k} \quad (53c)$$

Properties:

$$S_{\mathbf{x}}(F) = S_{\mathbf{x}}(-F) \quad (54a)$$

$$S_{\mathbf{x}}(F) \geq 0, \quad \forall F \quad (54b)$$

$$S_{\mathbf{x}}(F) \in \mathbb{R} \quad (54c)$$

$$S_{\mathbf{x}}(f) = S_{\mathbf{x}}(-f) \quad (54d)$$

$$S_{\mathbf{x}}(f) \geq 0, \quad \forall f \quad (54e)$$

$$S_{\mathbf{x}}(f) \in \mathbb{R} \quad (54f)$$

$$S_{\mathbf{x}}(f) = S_{\mathbf{x}}(f + 1) \quad (54g)$$

Average power

$$P_{\mathbf{x}} = E[\mathbf{x}^2(t)] = R_{\mathbf{x}}(0) = \int_{-\infty}^{\infty} S_{\mathbf{x}}(F) dF \quad (55a)$$



$$P_x = E[x^2[n]] = R_x[0] = \int_{-\frac{1}{2}}^{\frac{1}{2}} S_x(f) df \quad (55b)$$

## 5.2 White Noise & White Gaussian Noise (WGN) Process

White noise process is SSS (WSS) process that is characterized by

$$R_n(\tau) = \sigma^2 \delta(\tau) \quad (56a)$$

$$S_n(F) = \sigma^2 \quad \forall F \quad (56b)$$

For WGN process,  $\mathbf{n}(t) \sim N(0, \sigma^2)$ ,

$$R_n(\tau) = \frac{N_0}{2} \delta(\tau) \quad (57a)$$

$$S_n(F) = \frac{N_0}{2} \quad \forall F \quad (57b)$$

## 5.3 Relation Between Covariance Matrix & Auto-covariance

Given WSS process  $\mathbf{x}(t)$ , the corresponding correlation matrix of  $\mathbf{X} = [\mathbf{x}(t_1), \dots, \mathbf{x}(t_N)]^T$  is given by

$$R_X = E[\mathbf{X}\mathbf{X}^T] \quad (58)$$

$$R_X(i, j) = E[X_i X_j] = R_x(|t_i - t_j|) \quad (59)$$

## 6 Cross-Signal

- Cross-correlation

$$R_{xy}(t_1, t_2) = E[\mathbf{x}(t_1)\mathbf{y}(t_2)] \quad (60)$$

- Cross-covariance

$$C_{xy}(t_1, t_2) = R_{xy}(t_1, t_2) - E[\mathbf{x}(t_1)]E[\mathbf{y}(t_2)] \quad (61)$$

- Correlation Coefficient

$$\rho_{xy}(t_1, t_2) = \frac{C_{xy}(t_1, t_2)}{\sqrt{C_x(t_1, t_1)C_y(t_2, t_2)}} \quad (62)$$

## 6.1 WSS Cross-signal

- $\mathbf{x}(t), \mathbf{y}(t)$  are jointly WSS, if  $\mathbf{x}(t)$  and  $\mathbf{y}(t)$  each of them is WSS and

$$R_{xy}(\tau) = E[\mathbf{x}(t)\mathbf{y}(t + \tau)] \quad (63)$$

- When  $\mathbf{x}(t)$  and  $\mathbf{y}(t + \tau)$  are *uncorrelated jointly WSS*,  $C_{xy}(\tau) = 0$ .

Properties

$$R_{xy}(\tau) = R_{yx}(-\tau) \quad (64a)$$

$$|R_{xy}(\tau)| \leq \sqrt{R_x(0)R_y(0)} \quad (64b)$$

$$|R_{xy}(\tau)| \leq \frac{1}{2} [R_x(0) + R_y(0)] \quad (64c)$$

- Cross-covariance

$$C_{xy}(\tau) = R_{xy}(\tau) - \mu_x \mu_y \quad (65)$$

- Cross-PSD

$$S_{xy}(f) = \mathcal{F}\{R_{xy}(\tau)\} \quad (66)$$

Properties

$$S_{xy}(f) = S_{yx}(-f) = S_{xy}^*(-f) \quad (67)$$

Correlation coefficient

$$\rho_{xy}(\tau) = \frac{C_{xy}(\tau)}{C_{xy}(0)} \quad (68)$$

- Coherence

$$\gamma_{xy}(f) = \frac{S_{xy}(f)}{\sqrt{S_x(f)S_y(f)}} \quad (69)$$

## 7 LTI and WSS Random Process

Output of LTI system with impulse response  $h(t)$  and random process  $x(t)$ ,

$$y(t) = x(t) * h(t) \quad (70)$$

Average

$$m_y = m_x \int_{-\infty}^{\infty} h(s) ds = m_x H(F=0) \quad (71)$$

Cross-correlation & cross-covariance:

$$R_{xy}(\tau) = R_x(\tau) * h(\tau) \quad (72a)$$

$$C_{xy}(\tau) = C_x(\tau) * h(\tau) \quad (72b)$$

$$R_{yx}(\tau) = R_x(\tau) * h(-\tau) \quad (72c)$$

$$C_{yx}(\tau) = C_x(\tau) * h(-\tau) \quad (72d)$$

$$R_y(\tau) = R_x(\tau) * h(\tau) * h(-\tau) \quad (72e)$$

$$C_y(\tau) = C_x(\tau) * h(\tau) * h(-\tau) \quad (72f)$$

$$S_{yz}(z) = S_x(z)H_1(1/z)H_2(z) \quad (78c)$$

Power-Spectral Density (PSD) & Cross-PSD:  
Given frequency response

$$H(F) = \mathcal{F}\{h(\tau)\}, H^*(F) = \mathcal{F}\{h(-\tau)\}$$

$$S_{xy}(F) = S_x(F)H(F) \quad (73a)$$

$$S_{yx}(F) = S_x(F)H^*(F) \quad (73b)$$

$$S_y(F) = S_x(F)|H(F)|^2 \quad (73c)$$

Power of the process:

$$P_y = R_y(0) = \int_{-\infty}^{\infty} S_x(F)|H(F)|^2 dF \quad (74)$$

Same process passes two different systems

$$R_{yz}(\tau) = R_x(\tau) * h_1(-\tau) * h_2(\tau) \quad (75)$$

$$S_{yz}(F) = S_x(F)H_1^*(F)H_2(F) \quad (76)$$

## 7.1 Discrete-Time

Auto-correlation

$$H(z) = \mathcal{Z}\{h[n]\} = \frac{B(z)}{A(z)}$$

$$\mathcal{Z}\{h[n] * h[-n]\} = \frac{B(z)B(z^{-1})}{A(z)A(z^{-1})}$$

$$S_x(z) = \mathcal{Z}\{R_x[n]\}$$

$$h[k] * h[-k] = \sum_m h[m]h[m+k]$$

PSD

$$S_{xy}(z) = S_x(z)H(z) \quad (77a)$$

$$S_{yx}(z) = S_x(z)H(z^{-1}) \quad (77b)$$

$$S_y(z) = S_x(z)H(z)H(z^{-1}) \quad (77c)$$

Two different systems

$$R_{yz}[k] = R_x[k] * h_1[-k] * h_2[k] \quad (78a)$$

$$S_{yz}(f) = S_x(f)H_1^*(f)H_2(f) \quad (78b)$$

## 7.3 Linear Prediction

Given  $N$  samples of process  $\mathbf{x}[n]$ , and predictor

$$\hat{\mathbf{x}}[n+1] = \sum_{i=1}^N a_i \mathbf{x}[n-i+1], \quad (83)$$

the mean-square error is given by

$$\begin{aligned} mse &= E \left[ (\mathbf{x}[n+1] - \hat{\mathbf{x}}[n+1])^2 \right] \\ &= E \left[ (\mathbf{x}[n+1] - a_0 \mathbf{x}[n] - a_1 \mathbf{x}[n-1] - \dots - a_N \mathbf{x}[n-N])^2 \right] \end{aligned} \quad (84)$$

Power of the process:

$$P_x = R_x[0] = \int_{-1/2}^{1/2} S_x(f) df \quad (79a)$$

$$P_y = R_y[0] = \int_{-1/2}^{1/2} S_x(f) |H(f)|^2 df \quad (79b)$$

Average

$$\mu_y = \mu_x \sum_m h[m] \quad (80)$$

For white Gaussian noise input

$$\text{Var}[\mathbf{y}[n]] = \text{Var}[\mathbf{x}[n]] \sum_m h^2[m] \quad (81)$$

## 7.2 Gaussian Process

A Gaussian process  $\mathbf{x}(t)$  a random process that for  $\forall k > 0$  and for all times  $t_1, \dots, t_k$ , the set of random variable  $\mathbf{x}(t_1), \dots, \mathbf{x}(t_k)$  is jointly Gaussian.

Properties:

- WSS Gaussian process is SSS.
- Gaussian process  $\mathbf{x}(t)$  that passes through LTI system,  $\mathbf{y}(t) = h(t) * \mathbf{x}(t)$ , is also Gaussian process that may be described by the change of expectation and auto-correlation,

$$E[\mathbf{y}(t)] = E[\mathbf{x}(t)] \int_{-\infty}^{\infty} h(s) ds \quad (82a)$$

$$= E[\mathbf{x}(t)]H(0), \quad H(F) = \mathcal{F}\{h(t)\}$$

$$C_y(\tau) = C_x(\tau) * h(\tau) * h(-\tau) \quad (82b)$$

- The resulting autocorrelation may be used for producing the correspondent covariance matrix  $C_Y$  of a multivariate Gaussian  $\mathbf{Y} = [\mathbf{y}(t_1), \dots, \mathbf{y}(t_N)]^T$

and the values of  $a_i$  are given by a solution of

$$\begin{bmatrix} R_{\mathbf{x}}[0] & R_{\mathbf{x}}[1] & \cdots & R_{\mathbf{x}}[N-1] \\ R_{\mathbf{x}}[1] & R_{\mathbf{x}}[0] & \cdots & R_{\mathbf{x}}[N-2] \\ \vdots & \vdots & \ddots & \vdots \\ R_{\mathbf{x}}[N-1] & R_{\mathbf{x}}[N-2] & \cdots & R_{\mathbf{x}}[0] \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{bmatrix} = \begin{bmatrix} R_{\mathbf{x}}[1] \\ R_{\mathbf{x}}[2] \\ \vdots \\ R_{\mathbf{x}}[N] \end{bmatrix} \quad (85)$$

and the resulting minimum MSE is

$$mse_{min} = R_{\mathbf{x}}[0] - \sum_{i=1}^N a_i R_{\mathbf{x}}[i] \quad (86)$$

## 7.4 Match Filter

The goal of filter  $h(t)$  is to provide maximum SNR at time  $t = t_0$  for *deterministic* signal  $x(t)$  and noise  $n(t)$ .

$$H(f) = \alpha \frac{X^*(f)}{S_n(f)} e^{-j2\pi f t_0} \quad (87)$$

$$y(t) = \frac{1}{\alpha} R_v(t - t_0) \quad (88)$$

For white noise,  $n(t)$ , with  $S_N(f) = N_0/2$ , the filter

is given by

$$H_{mf}(f) = X^*(f) e^{-j2\pi f t_0} \longleftrightarrow h_{mf}(t) = x(t_0 - t) \quad (89)$$

and the resulting maximum SNR is given by

$$SNR_{max} = \frac{2}{N_0} \int_{-\infty}^{\infty} |X(f)|^2 df = \frac{2E_x}{N_0} \quad (90)$$

## 8 Different Supplementary Formulas

### 8.1 Derivatives

$$\frac{d}{dx} x^n = nx^{n-1}$$

$$\frac{d}{dx} \exp[f(x)] = \exp[f(x)] \frac{d}{dx} f(x)$$

### 8.2 Integrals

#### 8.2.1 Indefinite

$$\int x^n dx = \frac{1}{n+1} x^{n+1}, \quad n \neq -1$$

$$\int \exp(ax) dx = \frac{1}{a} \exp(ax)$$

$$\int x \exp(ax) dx = \exp(ax) \left[ \frac{x}{a} - \frac{1}{a^2} \right]$$

$$\int x^2 \exp(ax) dx = \exp(ax) \left[ \frac{x^2}{a} - \frac{2x}{a^2} + \frac{2}{a^3} \right]$$

$$\int \frac{1}{a^2 + x^2} dx = \frac{1}{a} \tan^{-1} \frac{x}{a}$$

$$\int \cos(ax + b) dx = \frac{\sin(ax + b)}{a}$$

#### 8.2.2 Definite

$$\int_0^{\infty} \exp(-a^2 x^2) dx = \frac{\sqrt{\pi}}{2a}$$

$$\int_0^{\infty} x^2 \exp(-a^2 x^2) dx = \frac{\sqrt{\pi}}{4a^3}$$

$$\int_{-\infty}^{\infty} \delta(x) dx = 1$$

$$\int_{-\infty}^{\infty} f(x) \delta(x - a) dx = f(a)$$

### 8.3 Fourier Transform

#### 8.3.1 Properties

$$\frac{d^n}{dt^n} g(t) \xleftrightarrow{\mathcal{F}} (j2\pi F)^n G(F)$$

$$g(-t) \xleftrightarrow{\mathcal{F}} G^*(F)$$

$$g(t - t_0) \xleftrightarrow{\mathcal{F}} G(F) e^{-j2\pi F t_0}$$

$$g(t) e^{j2\pi f_0 t} \xleftrightarrow{\mathcal{F}} G(F - F_0)$$

### 8.3.2 Transform pairs

$$\begin{aligned}
u(t) &\xleftrightarrow{\mathcal{F}} \frac{1}{2} \left( \frac{1}{j\pi F} + \delta(F) \right) \\
\exp(-at)u(t) &\xleftrightarrow{\mathcal{F}} \frac{1}{a + j2\pi F} \\
t \exp(-at)u(t) &\xleftrightarrow{\mathcal{F}} \frac{1}{(a + j2\pi F)^2} \\
\exp(-a|t|) &\xleftrightarrow{\mathcal{F}} \frac{2a}{a^2 + 4\pi^2 F^2} \\
\exp(-at^2) &\xleftrightarrow{\mathcal{F}} \sqrt{\frac{\pi}{a}} \exp\left(-\frac{(\pi F)^2}{a}\right) \\
\cos(2\pi f_a t) &\xleftrightarrow{\mathcal{F}} \frac{1}{2} [\delta(F - F_a) + \delta(F + F_a)] \\
\sin(2\pi f_a t) &\xleftrightarrow{\mathcal{F}} \frac{1}{2j} [\delta(F - F_a) - \delta(F + F_a)] \\
u(t+a) - u(t-a) &\xleftrightarrow{\mathcal{F}} \text{sinc}(2\pi F a) \quad \text{pulse in time} \\
\text{sinc}(2\pi F a) &\xleftrightarrow{\mathcal{F}} u(F+a) - u(F-a)
\end{aligned}$$

### 8.4 Convolution

$$x(t) * y(t) = \int_{-\infty}^{\infty} f(s)g(t-s)ds$$

$$\begin{aligned}
x(t) * y(t) &\xleftrightarrow{\mathcal{F}} X(F)Y(F) \\
\delta(t) * y(t) &= y(t)
\end{aligned}$$

### 8.5 Trigonometry

$$\begin{aligned}
\sin^2(\alpha) &= \frac{1}{2} (1 - \cos(2\alpha)) \\
\cos^2(\alpha) &= \frac{1}{2} (1 + \cos(2\alpha)) \\
\cos(\alpha) \cos(\beta) &= \frac{1}{2} [\cos(\alpha + \beta) + \cos(\alpha - \beta)] \\
\sin(\alpha) \sin(\beta) &= \frac{1}{2} [\cos(\alpha - \beta) - \cos(\alpha + \beta)] \\
\sin(\alpha) \cos(\beta) &= \frac{1}{2} [\sin(\alpha - \beta) + \sin((\alpha + \beta))]
\end{aligned}$$

### 8.6 Matrices

$$\begin{aligned}
\mathbf{A} &= \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \\
\det[\mathbf{A}] &= ad - bc \\
\mathbf{A}^{-1} &= \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}
\end{aligned}$$

## 9 Discrete-Time

Series sum

$$\begin{aligned}
\sum_{n=0}^{N-1} r^n &= \frac{1 - r^N}{1 - r} \\
\sum_{n=N_1}^{N_2-1} r^n &= \frac{r^{N_1} - r^{N_2}}{1 - r} \quad N_1 \leq N_2 \\
\sum_{n=0}^{\infty} r^n &= \frac{1}{1 - r} \quad |r| < 1 \\
\sum_{n=N_1}^{\infty} r^n &= \frac{1}{1 - r^{N_1}} \quad |r| < 1 \\
\sum_{n=0}^{\infty} nr^n &= \frac{r}{(1 - r)^2} \quad |r| < 1
\end{aligned}$$

### 9.1 Z-transforms

$$X(z) = \sum_{k=-\infty}^{\infty} x[k]z^{-k}$$

Signal	Z transform	ROC
$\delta[n]$	1	$\mathbb{C}$
$u[n]$	$\frac{1}{1 - z^{-1}}$	$ z  > 1$
$-u[-n - 1]$	$\frac{1}{1 - z^{-1}}$	$ z  < 1$
$\delta[n - m]$	$z^{-m}$	$\mathbb{C} - \{0\}$ if $m > 0$ , $\mathbb{C} - \{\infty\}$ if $m < 0$
$a^n u[n]$	$\frac{1}{1 - az^{-1}}$	$ z  > a$
$-a^n u[-n - 1]$	$\frac{1}{1 - az^{-1}}$	$ z  < a$

Property	Discrete Signal	Z transform	ROC
Linearity	$a_1 x_1[n] + a_2 x_2[n]$	$a_1 X_1(z) + a_2 X_2(z)$	includes $R_1 \cap R_2$
Time shift	$x[n - n_0]$	$z^{-n_0} X(z)$	$R$
Frequency scaling	$z_0^n x[n]$	$X\left(\frac{z}{z_0}\right)$	$ z_0 R$
Time reversal	$x[-n]$	$X(z^{-1})$	$R^{-1}$ if $m < 0$
Convolution	$(x_1 * x_2)[n]$	$X_1(z)X_2(z)$	$R_1 \cap R_2$ (or possibly more)
Accumulation	$\sum_{k=-\infty}^n x[k]$	$\frac{X(z)}{1 - z^{-1}}$	$R \cap \{ z  > 1\}$

## 9.2 DTFT

$$X(f) = X(z) \Big|_{z=e^{j\omega}} = \sum_{n=-\infty}^{\infty} x[n] e^{-jn\omega}$$

$$x[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} X(e^{j\omega}) e^{jn\omega} d\omega.$$