


למה יתר נקודות \Leftarrow ביצועים פחות?
 בדרך כלל: העלאה בדיוקת הביצועים
 ליתר הנקודות אפשרות



Generalization (הכללה)

בדיקת ביצועים: תאוריה \Leftarrow מדעית כלכלית (על מיליון)
 דוגמה חד-ממדית (א.מ.א.)
 \Leftarrow נדרוש כל אפשרות הסטטיסטית
 של (א.מ.א.) עם הסתברות שלהם
 \Leftarrow ביצועים: ממוצע עבור כל צורה א.מ.א.
 כפוף הסתברות

$$\text{MSE} = \left[\text{הסתברות של } \text{MSE}(\text{א.מ.א.}) \cdot \text{הצורה א.מ.א.} \right]$$

 שאלה: איך יוצרים עץ כלכלי קרובים
 דביצועים האולטימטי?
 הערה: תוצאה מדויקת עבור מספר
 ממוצע של דוגמאות סינטיטיות

מטרות:
 * מדידת של בדיקת ביצועים
 * ניתוח ביצועים
 * ביצועים של מטרות 'הצורה'

Polynomial model

- Goal:**
- Extension of a linear model "engine" to polynomial models. The polynomial model is very flexible, i.e. due to the Taylor expansion theorem.
 - Illustration of generalization principle.


The N -degree uni-variate polynomial model is

$$\hat{y} = f(x; \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \dots + w_N x^N$$

$$= \sum_{j=0}^N w_j x^j$$

למחזור המודל:
 * מהיכוח מודל חד-ממדי.
 בועצמאל-מחזורי-ממדי.
 רב-ממדי
 \Leftarrow w_j

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 & \dots & x_1^N \\ 1 & x_2 & x_2^2 & \dots & x_2^N \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_M & x_M^2 & \dots & x_M^N \end{bmatrix}$$



$$\hat{y}_k = \sum_{j=0}^N w_j x_k^j$$

$k = 1, \dots, M$

N - הפקת לקסימלי של פולינום



$$\hat{y}_k = \sum_{j=0}^N w_j z_{kj} \quad z_{kj} = x_k^j$$

$$\begin{bmatrix} 1 & x_M & x_M^2 & \dots & x_M^N \end{bmatrix}$$

$$\sum_{j=0}^N$$

ר.ב. נמנ. w_j \Leftarrow

$N=3$ סדר של פולינום



hyper-parameters

= פרמטרים של

למאמץ ישיבו

לחוק המנויים

דוגמא: סדר של

פולינום N



למאמץ של

פולינום: כמות



ש.מ.ש
ע.ח.י.ס.ב
מקדמי
הפולינום

י.ת.
הנקודות

צוהר על
כל הנקודות
ש.מ.ש
ע.ח.י.ס.ב



קו המידה בין צב
סדר של פולינום



דוגמא: ב.צ.מ. סולם

3.3 Overfitting and underfitting

Goal: Two common and fundamental **אבחונים** in machine learning.

Overfitting when model is too complex, i.e. have too many parameters.

$N=10$


- Too many hyper-parameters relative to the number of observations. *יותר מדי פרמטרים*
- Follow the training data very closely. *עוקב יותר מדי טוב*
- Fail to generalize well to unseen data.

Underfitting happens when a model is too simple.

- Unable to capture the underlying pattern of the data and hence misses the trends in the data. *מפסיד את המאפיין*
- Performs poorly on the training data and fail to generalize. *ב.צ.מ. גרוע*

Overfitting and underfitting are complementary and balancing between them is key to building robust machine learning models that perform well on new, unseen data, i.e. generalize well.

ב.צ.מ.



Hyper-parameter optimization The order N is the hyper-parameter of the polynomial model. Selecting the most appropriate hyper-parameters value is called hyper-parameter optimization.

ב.צ.מ. ב.צ.מ.

Cross-validation

למאמץ

הזיקה ביצורים

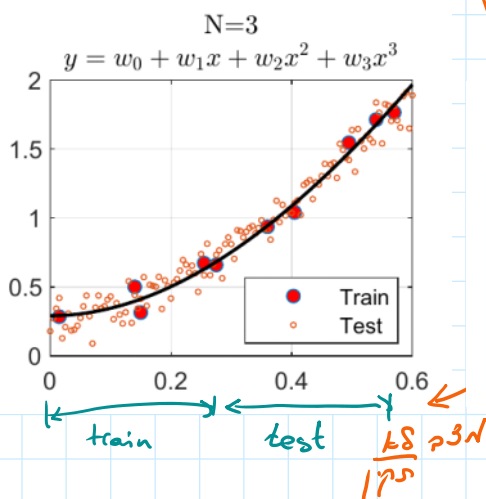
Cross-validation

ניסוי וטעייה

Goal: Trial and error approach to quantify generalization performance and overfitting-underfitting balance.

The cross-validation is also termed **performance assessment**.


- First step of any following technique is resample the dataset into the **random order**.



Medium datasets (100 - 1K)
k-fold



(1) חלוקה ל-k חלקים שונים
(2) כל פעם, חלק אחד הוא test
בגודל $k=5, 10$
עבור בסיס נתונים קטנים במיוחד $k=M$
one-fold-out



Bias-variance trade-off

הנחת יסודית עבור התחזית

כיצד לא יצא

$$y = h(x) + \epsilon$$


↓ ↓
הנחה רעש

* רעש עם ממוצע 0

ו-רעש שנותן σ^2

חזית ביטחון

דוגמה למספר



test: הטובה היא בבחינת החזית

פונקציה: MSE

$$\mathcal{L} = E[(\hat{y} - y)^2] = \frac{1}{M} \sum_{i=1}^M (\hat{y}_i - y_i)^2$$


$$= \underbrace{(E[\hat{y}] - h(x))^2}_{\text{bias}^2} + \underbrace{\text{Var}[\hat{y}]}_{\text{variance}} + \underbrace{\sigma^2}_{\text{noise}}$$

Handwritten notes: 'סטיית ממוצעת' (bias), 'שונות' (variance), 'רעש' (noise), 'שטח החזית' (prediction area).

* כדור עם ממוצע 0
 וסטימט שונה σ^2
 * משיגה של המודל: 88 אחוז (אח)


סטטיסטיקה ממוצעת
 של המדויק
 של המדויק
 trade-off

סטטיסטיקה ממוצעת
 בצורה



* סטטיסטיקה ממוצעת
 יחסית למידה
 + שטח
 שבו

מודל כושר מלא



מודל כ' - דוגמה למסכרת:

M_train = 10; *train*
 sigma = 0.1; *שטח הכדור*
 x_train = random('Uniform', 0, 0.6, M_train, 1); *אקראי x ~ U[0, 0.6]*
 p_coeff = [0.1 3 1 0.2 0.01]; *h(x)*
 y_theory_train = polyval(p_coeff, x_train);
 y_train = y_theory_train + sigma * randn(M_train, 1); *הוספת רעש*
 % y = x1 + 3*x1.^2 + 0.1*x1.^3 = h(x)
 M_test = 100; *test*
 x_test = random('Uniform', 0, 0.6, M_test, 1);
 y_theory_test = polyval(p_coeff, x_test);
 y_test = y_theory_test + 0.1 * randn(M_test, 1);

p_coeff = [0.1 3 1 0.2 0.01];
 $p(x) = p_1 x^4 + p_2 x^3 + p_3 x^2 + p_4 x + p_5$
 $h(x) = 0.01 + 0.2x + x^2 + 3x^3 + 0.1x^4 \rightarrow y = h(x) + \text{רעש}$

פונקציה למימוש למקדמי הפולינום

function [yh, w] = polynomial_regression_weights(x, y, N)
 M = size(x, 1);
 X = zeros(M, N+1);

שורות
עמודות


for k = 0:N
 X(:, k+1) = x.^k;
end

w = pinv(X) * y; % lsqminnorm(X, y)
 yh = X * w;
end

מימוש ערכי \hat{y} בהינתן מקדמים ו-א

function yh = polynomial_regression_values(x, w)
 M = size(x, 1);
 N = length(w) - 1;
 X = zeros(M, N+1);
 for k = 0:N
 X(:, k+1) = x.^k;
end
 yh = X * w;
end

$$\hat{y} = Xw$$

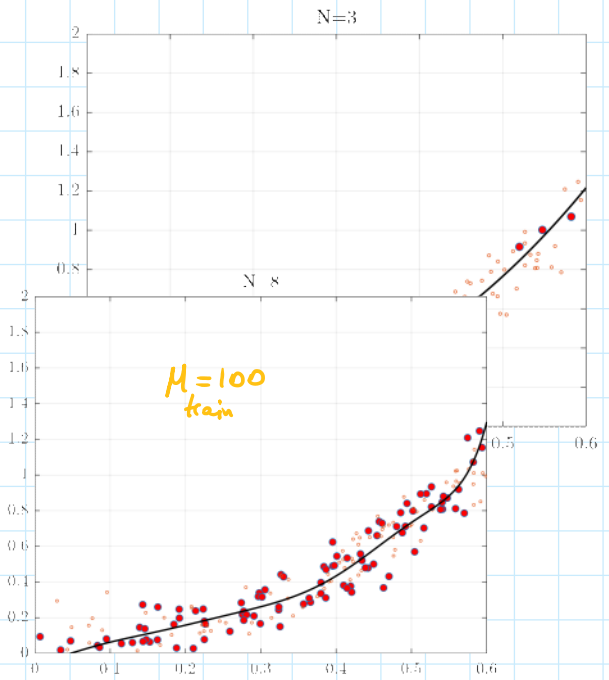
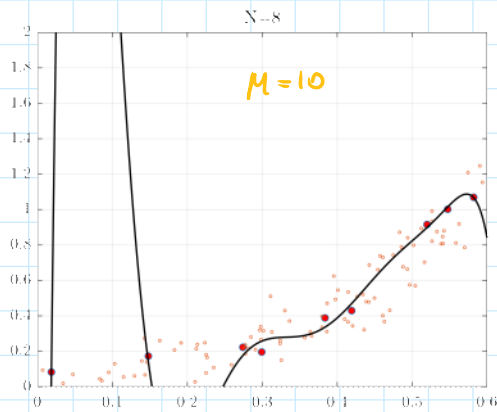


```

X = zeros(M,N+1);
for k = 0:N
    X(:,k+1) = x.^k;
end
yh = X*w;
end

```

$\hat{y} = \bar{X}w$



* הסרה: קוסט נמוך אולם עררר overfit

שיעור בית

* לקבלת בסיס נמוך.

* יש להסב/להצג ערך μ אופטימלי עבור הנתונים

* שלבים: (1) חישוב לקבלת μ_{train} (2) בדיקת ביצועים עבור μ נבחר (3) סיבוב בדיקת ביצועים עבור μ_{opt}

$\mu_{opt} \Leftarrow \begin{matrix} \text{validation} \\ \text{test} \end{matrix}$ אופטימלי