

Lec4 - Kernels

Monday, 24 June 2024 16:02

מכונות:

* פונ' מ'פוי רב-ממדי

* כריק מממ' ע'פונ' ע'פ' מ'פוי

ההיכ: יש קריבה אלגברה ע'פונ'אית

מ'פוי מ'פוי

$\phi(\cdot): \mathbb{R} \rightarrow \mathbb{R}$
פונ' מ'פוי

$L=2$

$$\phi(x_{k1}, x_{k2}) = [1, x_{k1}, x_{k2}, x_{k1}x_{k2}, x_{k1}^2, x_{k2}^2]$$

$L=2$

$N=6$

$K=1, \dots, M$

$N \times N$

מכונה: נ'תוח מ'פויים של $X^T X$

$$w_{opt} = (X^T X)^{-1} X^T y$$

$$X = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \in \mathbb{R}^{M \times 2}$$

וקט' שורה של נ'תוח

$$X^T X = \begin{bmatrix} x_1^T \\ x_2^T \end{bmatrix} \begin{bmatrix} x_1 & x_2 \end{bmatrix} = \begin{bmatrix} x_1^T x_1 & x_1^T x_2 \\ x_2^T x_1 & x_2^T x_2 \end{bmatrix}$$

סקלר

Kernel Trick

$$w = (X^T X + \lambda I)^{-1} X^T y = X^T (X X^T + \lambda I)^{-1} y$$

נ'תוח $X X^T$ של X , מ'פוי N ע'פונ'אית

M - מספר שורה מ'פוי, כ'פוי מ'פוי

$$X X^T = \begin{bmatrix} \tilde{x}_1^T \\ \vdots \\ \tilde{x}_j^T \\ \vdots \\ \tilde{x}_M^T \end{bmatrix} \begin{bmatrix} \tilde{x}_1 & \vdots & \tilde{x}_j & \vdots & \tilde{x}_M \end{bmatrix} = \begin{bmatrix} \tilde{x}_1^T \tilde{x}_1 & \cdots & \tilde{x}_1^T \tilde{x}_M \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \tilde{x}_j^T \tilde{x}_1 & \cdots & \tilde{x}_j^T \tilde{x}_M \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \tilde{x}_M^T \tilde{x}_1 & \cdots & \tilde{x}_M^T \tilde{x}_M \end{bmatrix}$$

$1 \times N$ $N \times 1 \rightarrow 1 \times 1$

$$x_k = \begin{bmatrix} x_{1k} \\ x_{2k} \\ \vdots \\ x_{Mk} \end{bmatrix}$$

$$X = \begin{bmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{j1} & x_{j2} \\ \vdots & \vdots \\ x_{M1} & x_{M2} \end{bmatrix} = \begin{bmatrix} \tilde{x}_1^T \\ \vdots \\ \tilde{x}_j^T \\ \vdots \\ \tilde{x}_M^T \end{bmatrix}$$

$\tilde{x}_j^T \leftarrow$ ש'פוי של פונ' מ'פוי

פונ' מ'פוי: $\phi(x_k) = [1, x_k, x_k^2, \dots, x_k^N]$

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^N \\ 1 & x_2 & x_2^2 & \cdots & x_2^N \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_M & x_M^2 & \cdots & x_M^N \end{bmatrix}$$

כ'פוי ע'פונ' מ'פוי

$$\phi(x_k) = [1 \quad x_k \quad x_k^2 \quad \cdots \quad x_k^N]$$

מספר שורה

* מקרה חד-ממדי

$x_j \leftarrow$ שילוב של פני מבו

$$\begin{bmatrix} \tilde{x}_M^T \tilde{x}_1 & \dots & \tilde{x}_M^T \tilde{x}_M \end{bmatrix}$$

$1 \times N \quad N \times 1 \rightarrow 1 \times 1$

Kernel

שילוב פני מבו

צורתה: כישור של סמנים

$$\phi(\tilde{x}_j^T) = [1, x_{j1}, x_{j2}, x_{j1}x_{j2}, x_{j1}^2, x_{j2}^2] = \phi(\tilde{x}_j)^T$$

הפלה של פני מבו של מליצה X

$$\phi(X) = \begin{bmatrix} \phi(\tilde{x}_1^T) \\ \vdots \\ \phi(\tilde{x}_j^T) \\ \vdots \\ \phi(\tilde{x}_M^T) \end{bmatrix} \in \mathbb{R}^{M \times N}$$

מאחר
מבו

XX^T במקום

$$\phi(X)\phi(X)^T = \begin{bmatrix} \phi(\tilde{x}_1)^T \phi(\tilde{x}_1) & \dots & \phi(\tilde{x}_1)^T \phi(\tilde{x}_M) \\ \phi(\tilde{x}_2)^T \phi(\tilde{x}_1) & \dots & \phi(\tilde{x}_2)^T \phi(\tilde{x}_M) \\ \vdots & \ddots & \vdots \\ \phi(\tilde{x}_M)^T \phi(\tilde{x}_1) & \dots & \phi(\tilde{x}_M)^T \phi(\tilde{x}_M) \end{bmatrix}$$

סקר

Kernel matrix The matrix $K \in \mathbb{R}^{M \times M}$,

$$K = \begin{bmatrix} K(\tilde{x}_1, \tilde{x}_1) & \dots & K(\tilde{x}_1, \tilde{x}_M) \\ K(\tilde{x}_2, \tilde{x}_1) & \dots & K(\tilde{x}_2, \tilde{x}_M) \\ \vdots & \ddots & \vdots \\ K(\tilde{x}_M, \tilde{x}_1) & \dots & K(\tilde{x}_M, \tilde{x}_M) \end{bmatrix}$$

מליצה של kernel \leftarrow מהחל פני מבו

$$w = X^T (XX^T + \lambda I)^{-1} y$$

והשתלם במק: y

חברה של kernel + מליצה
kernel trick

שלי חישוב של מקדמי w

① חישוב מליצה \tilde{K}

$$\alpha = (K + \lambda I_M)^{-1} y$$

②

מאחר $M \times M$ וקטור $M \times 1$ סמ M שורה

בגום החישוב, אין צורך ישר בשאר של K

$$w = \underbrace{\phi(X)^T}_{N \times M} \underbrace{\alpha}_{M \times 1}$$

③

סיכום:

1. חישוב ערך של וקטור α

2. חישוב $K()$

3. חזני סלל צורך בערך

w בצורה מפורטת

סיכום מאמצים

$$\varphi(\tilde{x}_0)^T \in \mathbb{R}^{1 \times N},$$

$$\varphi(X)^T \in \mathbb{R}^{N \times M}, \varphi(X) \in \mathbb{R}^{M \times N}$$

$$K(\tilde{x}_0, X) \in \mathbb{R}^{1 \times M}$$

חישוב בין \tilde{x}_0 לבין X (מקדמי)

$$w = \sum_{j=1}^M \alpha_j \varphi(\tilde{x}_j)$$

צריך
נוסחה
כישור

$$\hat{y}_0 = \sum_{j=1}^M \alpha_j \varphi(\tilde{x}_0)^T \varphi(\tilde{x}_j)$$

$$= \sum_{j=1}^M \alpha_j \varphi(\tilde{x}_0)^T \varphi(X)$$

$K(\tilde{x}_0, X)$

$$= K(\tilde{x}_0, X) \alpha$$

Kernel functions

Polynomial Kernel

$$K(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^T \mathbf{y} + c)^d \rightarrow N$$

אנדרגראד L

Example for $c=0, d=3, L=2$:

c קבוע
 d הפקד

$$K(\mathbf{a}, \mathbf{b}) = (\mathbf{a}^T \mathbf{b})^3 = \left(\underbrace{[a_1, a_2]}_{\text{אנדרגראד } L} \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} \right)^3$$

$$= (a_1 b_1 + a_2 b_2)^3$$

$$= a_1^3 b_1^3 + 3a_1^2 b_1^2 a_2 b_2 + 3a_1 b_1 a_2^2 b_2^2 + a_2^3 b_2^3$$

$$N = \binom{d+L-1}{d}$$

$$L=10, d=4, N = \binom{13}{4} = 715$$

תכונה: חישוב מסובך kernel לא צורך N מחזרה באופן מפורש

$$\begin{aligned} &= [a_1^3, \sqrt{3}a_1^2 a_2, \sqrt{3}a_1 a_2^2, a_2^3] \cdot [b_1^3, \sqrt{3}b_1^2 b_2, \sqrt{3}b_1 b_2^2, b_2^3]^T \\ &= \varphi(\mathbf{a})^T \varphi(\mathbf{b}) \end{aligned}$$

לדוגמה $L=2$ ו- $d=3$ \rightarrow $N=715$

צורה מסתעפת L שיתית

$$c=0, d=2$$

$$\varphi(\mathbf{a}) = \langle 1, \sqrt{2}a_1, \sqrt{2}a_1, \dots, \sqrt{2}a_L, a_1^2, a_2^2, \dots, a_L^2, \sqrt{2}a_1 a_2, \sqrt{2}a_1 a_3, \dots, \sqrt{2}a_1 a_L, \sqrt{2}a_2 a_3, \dots, \sqrt{2}a_{L-1} a_L \rangle$$

overfitting

100%

under fitting

50%

Gaussian Radial Basis Kernel (RBK)

The kernel definition is

Euclidean distance

$$K(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2b}\right)$$

kernel func

Due to Taylor expansion,

$$\exp(x) \approx 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots$$

this kernel has $N \rightarrow \infty$.

Kernel regression

lambda = 0.01;

c = 1;

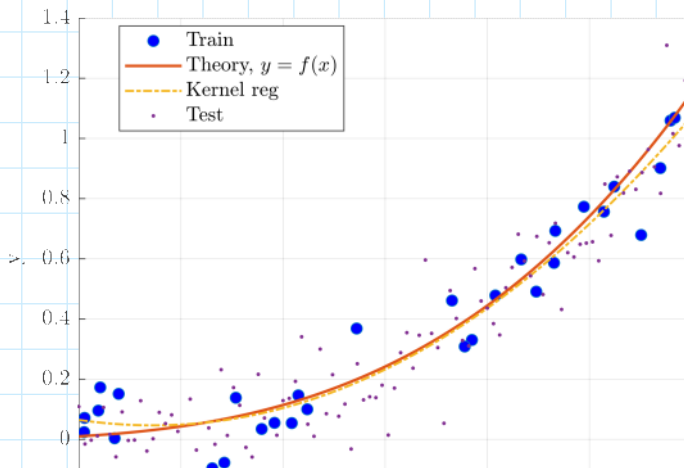
N = 5;

K_func = @(x1, x2) (x1*x2'+c).^N;

K = K_func(x_train, x_train);

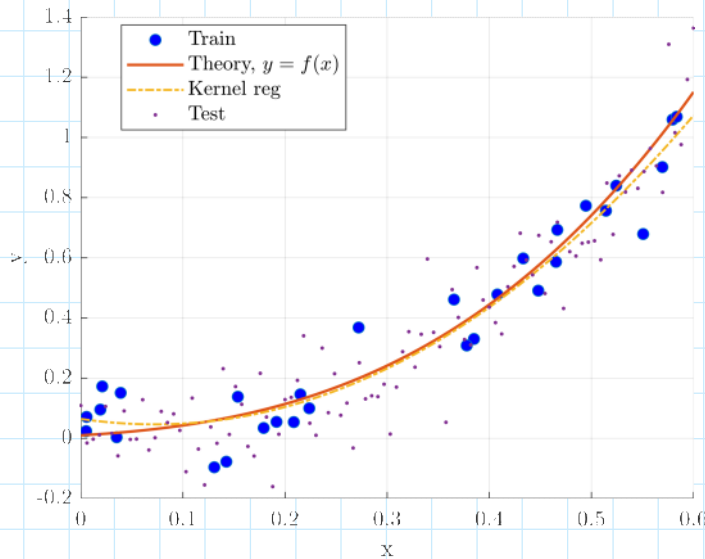
alpha = (K + lambda*eye(M_train))\y_train;

yh = K_func(x_test, x_train)*alpha;



$d=5$
 $c=1$
 $M_{train}=30$

$$K_{rbf} = @(x1, x2) \exp(-(x1-x2').^2/2/b);$$



$d=5$
 $c=1$
 $M_{train}=30$

$$K_{rbf} = @(x1, x2) \exp(-(x1-x2')^2/2/b);$$

סיכום:

* M לבנה שרירותית

* היפר-פרמטרים: λ


אנרגיה + פרמטרים שלה

* מבלה של היסוד עבור מטר-3 ממ M (מכונה kernel)

* מקדמי חצוי λ לא מתחשבים בצורה מבוהרת

← פחות ברור השפעה של λ על המודל.

התקנה ע"י Kernel



* עמים ממוצע לשוכלל

* נקודה קרובה יותר

← משקל בצורה יותר

שיטה:

$$\hat{y}_0 = \sum_{j=1}^M w_j y_j$$

משקלים

חישוב משקלים:

סיכום השיטה: * חישוב משקלים

$$\tilde{W} = K(\mathbf{X}_{test}, \mathbf{X}_{train}) \in \mathbb{R}^{M_{test} \times M_{train}}$$

* נרמול עמודות $W \leftarrow$

$$\hat{y}_{test} = W y_{train}$$

$$\tilde{w} = K(\tilde{x}_0, \mathbf{X})$$

נרמול סכום המשקלים $1-\delta$:

$$w_i = \frac{\tilde{w}_i}{\sum_{j=1}^M \tilde{w}_j}$$

סיכום:

* יחסית למשל חישבים

* היפר פרמטרים: $\text{par} + \text{kernel}$

* בצ"כ דורש גוונים "צבופים"

ברירתו של kernel

$b = .001;$

$\% b = .00005;$

פונ' kernel $K_{rbf} = @(x1, x2) \exp(-(x1-x2')^2/2/b);$

חישוב $W = K_{rbf}(x_{test}, x_{train});$

נרמול עמודות $W = W ./ \text{sum}(W, 2);$

$y_h = W * y_{train};$

עמודות