


Monday, 8 July 2024 16:15

משפט 13.3: (X_1, X_2) משותף

A 2D plot illustrating a linear decision boundary in a feature space with axes x_1 and x_2 . A blue curve separates the space into two regions. The region to the left of the curve is labeled $p(y=1) = 1$, and the region to the right is labeled $p(y=0) = 0$. Data points are shown as green 'x's and purple 'o's. A yellow square on the curve is labeled '2'.

שאלה: מה משמאל קו ישר - במקרה 13-14:




התחלה: ע'
מכפלה וקטורית
 $\mathbf{x}^T \mathbf{y} = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta)$
התחלה נקודה
אם לא לקו
דפי סימן
הצורה

$$x^T y \leq 0$$


linear regression : '0'02 δ_{31N}

$$\tilde{\mathbf{y}} = \mathbf{X}\mathbf{w}$$

$$\hat{y}_j = \begin{cases} 1 & \tilde{y}_j > \frac{1}{2} \\ 0 & \tilde{y}_j < \frac{1}{2} \end{cases}$$




א. ערכים
יכולים
עליה
עצומים
האכן
שירות.



μ σ^2 *
 - δ זיוף
 outliers

סקר



סקלה
 $\hat{y}_i = g(\mathbf{w}^T \mathbf{x}_i)$ לשפחה
 תוצאה סיווג
 פרמטרים
 נתון
 דטא



Logistic Model

- Linear model
- Outliers handling
- Probabilistic interpretation


$\hat{y} \sim p(y=1)$

linear regression - $g(x) = x$ basic linear model

logistic regression $g(x) = \frac{1}{1 + \exp(-x)}$ sigmoid = $\sigma(x)$
 $0 \leq \sigma(x) \leq 1$



$\sigma(x) = \frac{\exp(x)}{1 + \exp(x)} = \frac{1}{1 + \exp(-x)}$



Logistic regression:

$\hat{y}_i = \sigma(\mathbf{w}^T \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x}_i)}$
 $\hat{y} = \sigma(\mathbf{X}\mathbf{w})$

איך למצוא w?

MSE $\rightarrow \mathcal{L}(\cdot) = \frac{1}{2M} \|\hat{y} - y\|^2$

* אין פתרון אנליטי
 * יש הרבה תקופות למימוש המקומי
 * אלגוריתם

Cross-entropy loss

כוח למידה עם פרמטרים הסתברותיים

Entropy: For the discrete distribution $P = \{p_i = \Pr[X = x_i]\}$, the entropy is given by

$H(P) = - \sum_i p_i \log(p_i)$ (7.11)

למה: כמות של אי וודאות:
 $H(p)$ * יחידה אקראיות *
 $p_i = p_j$ * למקסימום של אקראיות *
 עבור התפלגות אחידה

$p_1 = p_2 = \frac{1}{2} \Rightarrow H(p) = -2 \cdot \frac{1}{2} \log_2\left(\frac{1}{2}\right) = 1$

$p_1 = \frac{1}{10}, p_2 = \frac{9}{10} \Rightarrow H(p) = -\frac{1}{10} \log_2\left(\frac{1}{10}\right) - \frac{9}{10} \log_2\left(\frac{9}{10}\right) \approx 0.4690$

Cross-entropy: For two discrete distributions, p and q , the cross-entropy is given by

$H(p, q) = - \sum_i p_i \log(q_i)$ (7.12)

$p_i = q_i$ * למינימום של $H(p, q)$ עבור
 $\Rightarrow H(p, q) = H(p)$
 * אם מצב אחר $H(p, q)$ יורד

Binary Cross-Entropy (BCE) Loss

$y \in \{0, 1\}$

$H(p, q) = -p_0 \log(q_0) - p_1 \log(q_1)$

* נתונים שלם - סיווג - בינארי
 * נתון ערוספסל של y כהסתברות
 $y = 1 \Rightarrow p(y=1) = 1$
 $p(y=1)$

$\Rightarrow H(p, q) = H(p)$
 \star אם נצב אחד $H(p, q)$ וזה

$y = 1 \Rightarrow p(y=1) = 1$ $p(y=1)$ "א"

$y = 0 \Rightarrow p(y=0) = 0$

$p_0 = \Pr(y = 0) = 1 - y \rightarrow$

$p_1 = \Pr(y = 1) = y \rightarrow$

$q_0 = \Pr(\hat{y} = 0) = 1 - f_w(x)$

$q_1 = \Pr(\hat{y} = 1) = f_w(x) \rightarrow$

לצב כזו

$f_w(x) \rightarrow 1$

$H(p, q) = -p_0 \log(q_0) - p_1 \log(q_1)$

$p_i = q_i$ עבור

$= -(1 - y) \log(1 - f_w(x)) - y \log(f_w(x))$

BCE loss: Binary cross-entropy (BCE) loss function

$\mathcal{L}(y, \hat{y}) = -(1 - y) \log(1 - \hat{y}) - y \log(\hat{y})$ (7.14)

$\mathcal{L} = -\frac{1}{M} \sum_{j=1}^M (1 - y_i) \log(1 - \hat{y}_i) + y_i \log(\hat{y}_i)$

$= -\frac{1}{M} [(1 - y) \log(1 - \hat{y}) + y \log(\hat{y})]$

פונ' למידה
 הכי גבוהה
 בשילוח סיום

* ג'י.ר
 * כזו
 * מינימום גלובלי יחיד

סיכום

Probabilistic prediction:

$p(y = 1 | x, w) = \sigma(\tilde{x}w)$

$p(y = 0 | x, w) = 1 - \sigma(\tilde{x}w)$



(7.16)

Classification decision: $\hat{y} \leq \frac{1}{2}$

Another way:

$\hat{y} = \begin{cases} 1 & \tilde{x}^T w \geq 0 \\ 0 & \tilde{x}^T w < 0 \end{cases}$

ס'מון
 (ס) גל



כמות
 מ-0.25

$\mathcal{L} = \frac{1}{M} [-y^T \log(\sigma(Xw)) - (1 - y)^T \log(1 - \sigma(Xw))]$

$\nabla_w \mathcal{L}(w) = \frac{1}{M} X^T (\sigma(Xw) - y)$

$\nabla_w \mathcal{L} = 0$

אין בתוך אלו

$w_{n+1} = w_n - \alpha \nabla_w \mathcal{L}(w)$

Gradient descent


מינימום ע"י ג'י.ר
 * מינימום גלובלי יחיד (BCE)
 * כמות נורמל regularization


- Regularization can be applied,

$\mathcal{L}_{new} = \mathcal{L}(y, \hat{y}) + \frac{\lambda}{2M} \sum_{i=1}^N w_i^2$ (7.21)

* נורמל מינימום גלובלי יחיד

$\phi(x_1, x_2) = \langle 1, x_1, x_1^2, x_2, x_2^2, x_1 x_2, x_1^2 x_2, x_1 x_2^2, x_1^2 x_2^2 \rangle$





k -NN

nearest neighbors

שיטה: החלטה ע"ב רוב השכנים
למק א הכי קרובים
 $k=1$ "שכן" הכי הקרוב (שכן יחיד)

* שיטה עמדה לרחוק:
היפר-ברמלה של השיטה

* תיקון: 2 שכנים סיווג 0
1 " " 2

- החלטה אקראית
- ע"ב שכן הכי קרוב

* עובד על מספר שניוני של קבוצה
סיווג



train

ביצועים

\rightarrow train בקול מביעים
 \leftarrow 8-100% עבור 1-NN

- Euclidean distance metric,

$$d(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|$$

$$= \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \dots + (a_M - b_M)^2} \quad (7.22)$$

- City block (Manhattan) distance

$$d(\mathbf{a}, \mathbf{b}) = \sum_{j=1}^M |a_j - b_j|$$

$$= |a_1 - b_1| + \dots + |a_M - b_M| \quad (7.23)$$

- Minkowski distance with (hyper) parameter p ,

$$d(\mathbf{a}, \mathbf{b}) = \sqrt[p]{\sum_{j=1}^M |a_j - b_j|^p} \quad (7.24)$$

* שיטה משלמה למבטא נאשוני
baseline performance

* סיבוכות חישובי.

עבור כל נקודה ב test

נדרש חישוב M איחוקים

של train

* 8% ממוצע
outliers ב

* חישוב עמדה נמוכה